

# APRENDIZAJE AUTOMÁTICO

Grado en Ingeniería Informática

Grupos 2 y 3

## Práctica 1 Ejercicio 2



UNIVERSIDAD  
DE GRANADA

# ÍNDICE

## *Modus operandi*

### Ejercicio 2. Regresión lineal

¿Qué es?

### Ejercicio 2. Regresión lineal

¿Qué es?

### Ejercicio 2. Regresión lineal

Métodos para el cálculo de constantes

Gradiente Descendente Estocástico

# MODUS OPERANDI

1. Cada apartado en un script
2. Los resultados numéricos y/o gráficas han de mostrarse por pantalla
3. El path de lectura de datos de un fichero auxiliar debe ser ".....datos/nombre\_fichero"
4. El código ha de ejecutarse completo sin errores
5. Comentar el código es obligatorio
6. Los puntos de parada para mostrar resultados y/o gráficas son necesarios
7. Todos los ficheros se entregan dentro de un zip
8. No entregar datos
9. Subir el zip a PRADO

# EJERCICIO 1. REGRESIÓN LINEAL

¿Qué es?


Se trata de un algoritmo matemático que cuantifica el grado de **dependencia** entre una **variable dependiente** ( $Y$ ) y una o varias **independientes / predictoras** ( $X_1, X_2, \dots, X_n$ ) mediante una **recta** (en  $\mathbb{R}^n$ ).

Buscamos entonces, determinar las constantes ( $w_i$  con  $i = 1, 2, \dots, n$ ,  $n \in \mathbb{N}$ ) de la siguiente ecuación:

$$y = w_0 + w_1 * x_1 + w_2 * x_2 + \dots$$

# EJERCICIO 1. REGRESIÓN LINEAL

¿Qué es?



# EJERCICIO 1. REGRESIÓN LINEAL

Métodos para el cálculo de constantes

## 1. Gradiente Descendente Estocástico

Es una **variante** del algoritmo Gradiente Descendente que busca disminuir el **costo computacional** y lo hace estudiando sólo una **muestra** del dataset (ejecutando varias veces con subconjuntos de datos aleatorios).

# EJERCICIO 1. REGRESIÓN LINEAL

Métodos para el cálculo de constantes

## 1. Gradiente Descendente Estocástico

### ► Gradiente descendente

$$\frac{\partial E_{in}(\mathbf{w})}{\partial w_j} = \frac{\partial}{\partial w_j} \frac{1}{N} \sum_{n=1}^N (\mathbf{w}^T \mathbf{x}_n - y_n)^2 = \frac{2}{N} \sum_{n=1}^N x_{nj} (\mathbf{w}^T \mathbf{x}_n - y_n) = \frac{2}{N} \sum_{n=1}^N x_{nj} (\mathbf{h}(\mathbf{x}_n) - y_n)$$

### ► Gradiente descendente (M<N)

$$\frac{\partial E_{in}(\mathbf{w})}{\partial w_j} = \frac{2}{M} \sum_{n=1}^M x_{nj} (\mathbf{h}(\mathbf{x}_n) - y_n)$$

# EJERCICIO 1. REGRESIÓN LINEAL

Métodos para el cálculo de constantes

## 1. Gradiente Descendente Estocástico

Ventajas:

- ▶ Computación rápida
- ▶ Mayor variabilidad en la estimación del gradiente
- ▶ Evidencia empírica de generar un buen mínimo local en funciones no convexas
- ▶ Muy útil para conjuntos con un gran número de datos

Inconvenientes:

- ▶ Puede que no se alcance el óptimo (exacto), pero se halle una aproximación muy razonable



# EJERCICIO 1. REGRESIÓN LINEAL

Métodos para el cálculo de constantes

## 2. Pseudoinversa

La pseudoinversa  $R$  de una matriz dada  $M$  es una variante de la inversa, que cumple que al multiplicarla por ambos lados (derecho e izquierdo) genera la identidad.

$$R = A^t(AA^t)^{-1}$$

¿Puede calcularse siempre?

# EJERCICIO 1. REGRESIÓN LINEAL

Métodos para el cálculo de constantes

## 2. Pseudoinversa

Buscamos entonces  $y = w_0 + w_1X$ , con  $w_0, w_1$  constantes, y la variable dependiente  $y$   $X$  la matriz de las variables independientes.

Minimizing  $E_{in}$  : normal equations

$$E_{in}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

$$\nabla E_{in}(\mathbf{w}) = \frac{2}{N} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = \mathbf{0}$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

$$\mathbf{w} = \mathbf{X}^\dagger \mathbf{y} \text{ where } \mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

$\mathbf{X}^\dagger$  is the 'pseudo-inverse' of  $\mathbf{X}$